# Stochastik Zusammenfassung

Mattis Seebeck

30.07.2020

# Inhaltsverzeichnis

**1. Definitionen** **3**

**2. Bedingte Wahrscheinlichkeit** **4**
2.1 Baumdarstellung . . . 4
2.2 Multiplikationsregel . . . 5
2.3 Additionsregel . . . 5
2.4 Formel der Gesamtwahrscheinlichkeit . . . 5
2.5 Unabhängige Ereignisse . . . 5
2.6 Bayes Umkehrformel . . . 5

**3. Zufallsvariablen** **6**
3.1 Verteilungsfunktion . . . 6
3.2 Wahrscheinlichkeitsfunktion . . . 6
3.3 Dichte . . . 7

**4. Gemeinsame Verteilung** **7**
4.1 Bedingte Wahrscheinlichkeit . . . 8
4.2 Unabhängigkeit . . . 8
4.3 Faltungsformel . . . 8

**5. Verteilungen** **9**
5.1 Gleichverteilung . . . 9
5.2 Bernoulli-Verteilung . . . 9
5.3 Binomialverteilung . . . 10
5.4 Geometrische Verteilung . . . 10
5.5 Poisson-Verteilung . . . 11
5.6 Exponentialverteilung . . . 12
5.7 Normalverteilung . . . 13
5.8 Chi-Quadrat-Verteilung . . . 14
5.9 $t$-Verteilung . . . 14
5.10 Wahrscheinlichkeiten von diskreten Verteilungen . . . 15
5.11 Wahrscheinlichkeiten von stetigen Verteilungen . . . 16

**6. Erwartungswert** **17**
6.1 Eigenschaften . . . 17
6.2 Dichte . . . 17

**7. Varianz** **18**
7.1 Chebyshev-Ungleichung . . . 18
7.2 Markov-Ungleichung . . . 18

**8. Kovarianz** **19**
8.1 Eigenschaften . . . 19
8.2 Korrelation . . . 19
8.3 Kovarianzmatrix . . . 19

**9. Markov-Ketten** **20**
9.1 Übergangswahrscheinlichkeiten . . . 20
9.2 Startverteilung . . . 22
9.3 Invariante Verteilung . . . 22
9.4 Bestimmung von invarianten Verteilungen . . . 22
9.5 Irreduzierbarkeit und Aperiodizität . . . 22

**10. Gesetz der großen Zahlen** **23**

**11. Zentraler Grenzwertsatz** **23**

**12. Statistik** **24**
12.1 Empirisches Mittel . . . 24
12.2 Median . . . 24
12.3 Empirische Varianz . . . 24
12.4 Empirische Kovarianz . . . 24
12.5 Schätzfunktion . . . 25
12.6 Maximum Likelihood Schätzung . . . 25
12.7 Log-Likelihood . . . 25
12.8 Vorgehen . . . 26
12.9 Eigenschaften von Schätzern . . . 26
12.10 Lineare Regression . . . 26

**13. Konfidenzbereiche** **27**

**14. Quantile** **27**
14.1 Quantile der Normalverteilung . . . 27

**15. Konstruktion von Konfidenzbereichen** **28**
15.1 Konfidenzbereich der Normalverteilung . . . 28
15.2 Konfidenzintervall für den Erwartungswert der Normalverteilung . . . 28
15.3 Konfidenzintervall für die Varianz der Normalverteilung . . . 28

**16. Testen von Hypothesen** **29**
16.1 Herangehensweise für ein Merkmal, einseitig . . . 29
16.2 Herangehensweise für ein Merkmal, zweiseitig . . . 30
16.3 Herangehensweise für zwei Merkmale, zweiseitig . . . 30
16.4 Chi-Quadrat-Test . . . 31
16.5 $p$-Wert . . . 33

# 1. Definitionen

Hier eine Liste von Definitionen, die im folgenden wichtig sind.

Die Menge aller Ergebnisse eines Experimentes wird Ergebnissmenge $\Omega$ genannt. Ein Ereignis ist eine Teilmenge $A \subseteq \Omega$. Ein Ergebnis wird als $\omega \in \Omega$ notiert.

Ein endlicher Wahrscheinlichkeitsraum ist ein Paar $(\Omega, \mathbb{P})$ bestehend aus einer endlichen Ergebnissmenge $\Omega$ und einer Funktion $\mathbb{P}$, welche jedem Ereignis $A \subseteq \Omega$ eine Wahrscheinlichkeit $\mathbb{P}(A)$ zuordnet. Dabei hat $\mathbb{P}$ folgende eigenschaften:

$$\forall A \subseteq \Omega: \quad 0 \leq \mathbb{P}(A) \leq 1 \tag{1}$$

$$\mathbb{P}(\Omega) = 1 \tag{2}$$

$$\forall A, B \subseteq \Omega: \quad \mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \tag{3}$$

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A) \tag{4}$$

$$\mathbb{P}(\emptyset) = 0 \tag{5}$$

$$\forall A \subseteq B \subseteq \Omega: \quad \mathbb{P}(A) \leq \mathbb{P}(B) \tag{6}$$

Die Größe $H_n(A)$ bezeichnet die absolute Häufigkeit für das Eintreten von $A$ bei $n$ Versuchen.
Die Größe $h_n(A) = \dfrac{H_n(A)}{n}$ bezeichnet die relative Häufigkeit für das Eintreten von $A$ bei $n$ Versuchen.

# 2. Bedingte Wahrscheinlichkeit

Die bedingte Wahrscheinlichkeit von $A$ unter der Bedingung, dass $B$ eingetreten ist, ist definiert durch

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \tag{7}$$

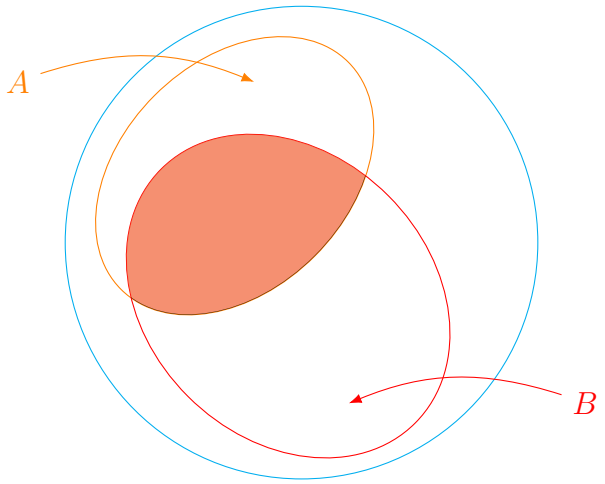


Wenn wir wissen, dass $B$ eingetreten ist, dann ist nur noch der rote Bereich von $B$ möglich. Der Bereich $B$ wird also zu $\Omega$ und das Wahrscheinlichkeitsmaß muss dahingehend normiert werden. Deshalb wird durch $\mathbb{P}(B)$ geteilt. Der noch noch erreichbare Bereich von $A$ ist nur noch der Schnitt von $A$ und $B$. Entsprechend ist dies die noch mögliche Fläche für $A$. Deswegen ist im Zähler $\mathbb{P}(A \cap B)$. Daraus setzt sich (7) zusammen.

## 2.1 Baumdarstellung

Man kann bedingte Wahrscheinlichkeiten wie folgt darstellen:

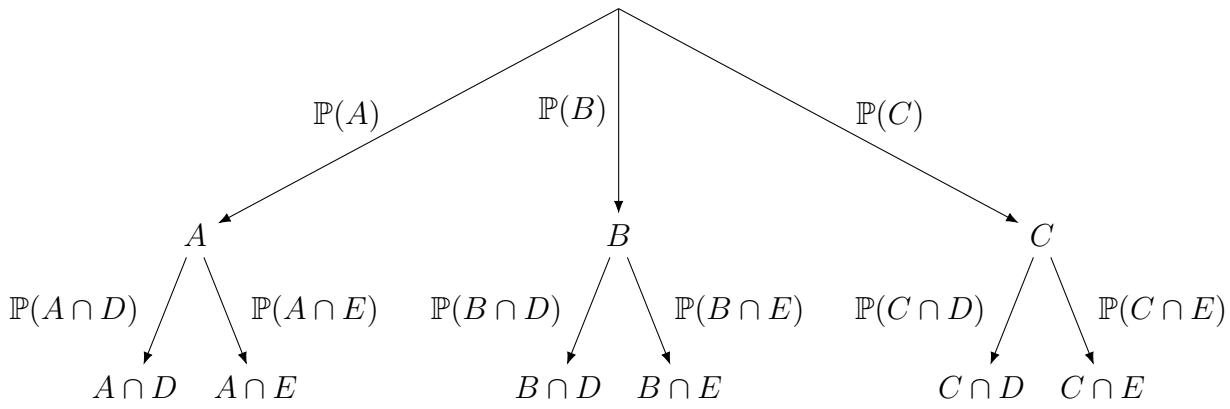

## 2.2 Multiplikationsregel

Umformen der Definition der bedingten Wahrscheinlichkeit führt auf

$$\mathbb{P}(A \cap B) = \mathbb{P}(B) \cdot \mathbb{P}(A \mid B) \tag{8}$$

Deswegen kann man in einem mehrstufigen Experiment die Wahrscheinlichkeit eines Ergebnisses, z.B. $A \cap D$ durch Multiplikation der Wahrscheinlichkeiten entlang der Äste, die zum Blatt führen, berechnen. In diesem Beispiel ist das $\mathbb{P}(A \mid D) = \mathbb{P}(A) \cdot \mathbb{P}(A \cap D)$.

## 2.3 Additionsregel

In einem mehrstufigen Experiment berechnet sich die Wahrscheinlichkeit für ein Ereignis durch Addition der entsprechenen Einzelwahrscheinlichkeiten der Ergebnisse auf den Blättern des Baumes, welche in das Ereignis eingehen. Möchte man also die Wahrscheinlichkeit für das Ereignis $D$ berechnen, so muss man folgendes berechnen:

$$\mathbb{P}(D) = \mathbb{P}(A \cap D) + \mathbb{P}(B \cap D) + \mathbb{P}(C \cap D) \tag{9}$$

## 2.4 Formel der Gesamtwahrscheinlichkeit

Mit der Multiplikationsregel und der Additionsregel kann man die Wahrscheinlichkeit von dem Ereignis $D$ wie folgt berechnen:

$$\mathbb{P}(D) = \mathbb{P}(A) \cdot \mathbb{P}(D \mid A) + \mathbb{P}(B) \cdot \mathbb{P}(D \mid B) + \mathbb{P}(C) \cdot \mathbb{P}(D \mid C) \tag{10}$$

Allgemeiner: Sei $(\Omega, \mathbb{P})$ ein Wahrscheinlichkeitsraum und sei $A$ ein Ereignis. Sei $B_1, \ldots, B_n$ eine disjunkte Zerlegung von $\Omega$. Dann gilt

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i) \tag{11}$$

## 2.5 Unabhängige Ereignisse

Zwei Ereignisse heißen unabhängig, falls folgendes gilt

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \tag{12}$$

$$\Leftrightarrow \qquad \mathbb{P}(A \mid B) = \mathbb{P}(A) \tag{13}$$

## 2.6 Bayes Umkehrformel

Seien $A, B$ Ereignisse mit $0 < \mathbb{P}(B) < 1$ und $\mathbb{P}(A) > 0$. Dann gilt

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \mid B) \cdot \mathbb{P}(B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B) \cdot \mathbb{P}(B)}{\mathbb{P}(A \mid B) \cdot \mathbb{P}(B) + \mathbb{P}(A \mid B^c) \cdot \mathbb{P}(B^c)} \tag{14}$$

Die allgemeine Variante der Formel lautet wie folgt:

Seien $A, B_1, \ldots, B_n$ Ereignisse mit $\mathbb{P}(A) > 0$, $\forall i, j \in [n] : \mathbb{P}(B_i) > 0 \wedge B_i \cap B_j = \emptyset$ und $\bigcup\limits_{i=1}^{n} B_i = \Omega$. Dann gilt

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i)}{\sum\limits_{j=1}^{n} \mathbb{P}(A \mid B_j) \cdot B_j} \tag{15}$$

# 3. Zufallsvariablen

Eine Zufallsvariable auf $(\Omega, \mathbb{P})$ ist eine Abbildung

$$X : \Omega \to \mathbb{R} \tag{16}$$

Der Wertebereich einer Zufallsvariablen $X$ ist

$$X(\Omega) = \{x \in \mathbb{R} \mid \exists \omega \in \Omega : X(\omega) = x\} \subseteq \mathbb{R} \tag{17}$$

Wenn $X(\Omega)$ endlich oder abzählbar unendlich ist, so heißt $X$ diskrete Zufallsvariable. Falls dies nicht der Fall ist heißt $X$ stetige Zufallsvariable.

Für $E \subseteq X(\Omega)$ bzw. für $x \in X(\Omega)$ schreiben wir kurz

$$\mathbb{P}(X \in E) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in E\}) \tag{18}$$

$$\mathbb{P}(X = E) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) = x\}) \tag{19}$$

$$\mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\}) \tag{20}$$

## 3.1 Verteilungsfunktion

Die (kumulative) Verteilungsfunktion $F_X$ von $X$ ist definiert durch

$$F_X : \mathbb{R} \to [0, 1], \quad x \mapsto \mathbb{P}(X \leq x) \tag{21}$$

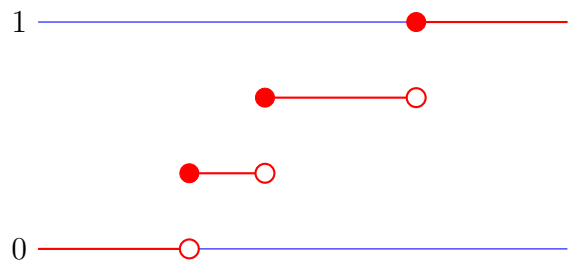


Abbildung 1: Diskrete Verteilungsfunktion

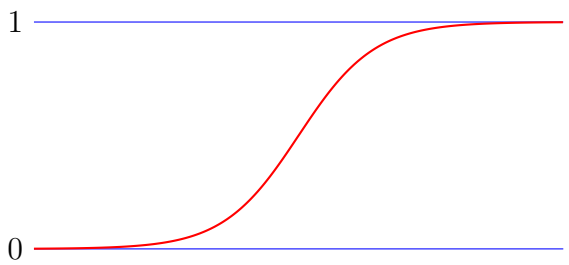


Abbildung 2: Stetige Verteilungsfunktion

Im diskreten Fall kann $F_X$ durch einfaches addieren der Wahrscheinlichkeiten für die jeweiligen intervalle gefunden werden.

Im stetigen Fall kann $F_X$ durch (stückweises) integrieren der Dichte gefunden werden.

## 3.2 Wahrscheinlichkeitsfunktion

Die Verteilung $p_X$ von $X$ ist definiert durch

$$p_X : \mathbb{R} \to [0, 1], \quad x \mapsto \mathbb{P}(X = k) \tag{22}$$

wobei außerdem $\forall k \notin X(\Omega) : p_X(k) = 0$ gilt.

### 3.3 Dichte

Sei $X$ eine Zufallsvariable mit Verteilungsfunktion $F_X$. Dann besitzt $X$ bzw. $F_X$ eine Dichte, falls eine Funktion $f_X : \mathbb{R} \to \mathbb{R}$ existiert, so dass $\forall x \in \mathbb{R}$ gilt

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t \tag{23}$$

Die Funktion $f_X$ muss folgende Eigenschaften erfüllen:

$$\forall t \in X(\Omega) : f(t) \geq 0 \tag{24}$$

$$\int_{-\infty}^{\infty} f(t)\,\mathrm{d}t = 1 \tag{25}$$

## 4. Gemeinsame Verteilung

Seien $X$ und $Y$ zwei diskrete Zufallsvariablen, welche auf dem selben Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$ definiert sind. Die gemeinsame Verteilung von $X$ und $Y$ ist gegeben durch die Kollektion der Wahrscheinlichkeiten

$$\mathbb{P}(X = k,\, Y = y) = \mathbb{P}(\{X = x\} \cap \{X = x\}), \quad x \in X(\Omega), y \in Y(\Omega) \tag{26}$$

Die Verteilung wird oft in einer Tabelle wie folgt dargestellt:

| $X \backslash Y$ | 0 | 1 | 2 | $p_X$ |
|---|---|---|---|---|
| 0 | $\frac{1}{16}$ | $\frac{1}{16}$ | 0 | $\frac{1}{8}$ |
| 1 | $\frac{2}{16}$ | $\frac{3}{16}$ | $\frac{1}{16}$ | $\frac{3}{8}$ |
| 2 | $\frac{1}{16}$ | $\frac{3}{16}$ | $\frac{2}{16}$ | $\frac{3}{8}$ |
| 3 | 0 | $\frac{1}{16}$ | $\frac{1}{16}$ | $\frac{1}{8}$ |
| $p_Y$ | $\frac{1}{4}$ | $\frac{1}{2}$ | $\frac{1}{4}$ | 1 |

Auf der rechten Seite sind die Randverteilungen von $X$ bzw. $Y$ eingetragen. Diese berechnen sich über

$$\mathbb{P}(X = x) = \sum_{y \in Y(\Omega)} \mathbb{P}(X = x, Y = y) \tag{27}$$

$$\mathbb{P}(X = y) = \sum_{x \in X(\Omega)} \mathbb{P}(X = x, Y = y) \tag{28}$$

Die Randverteilungen sind also die Zeilen bzw. Spaltensummen der Tabelle.

## 4.1 Bedingte Wahrscheinlichkeit

Auch hier lässt sich eine bedingte Wahrscheinlichkeit definieren:

$$\mathbb{P}(X = x \mid Y = y) = \frac{\mathbb{P}(X = x,\, Y = y)}{\mathbb{P}(Y = y)} \tag{29}$$

## 4.2 Unabhängigkeit

Zwei Zufallsvariablen $X$ und $Y$ sind genau dann unabhängig, wenn folgendes gilt:

$$\forall x \in X(\Omega), y \in Y(\Omega) : \mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \cdot \mathbb{P}(Y = y) \tag{30}$$

Unabhängigkeit kann man in einer Tabelle sehr gut überprüfen indem man schaut, wo die multiplizierten Randwahrscheinlichkeiten nicht übereinstimmen mit dem, was in der Tabelle steht. In dem obigen Beispiel gäbe es z.B.

$$\mathbb{P}(X = 0,\, y = 0) = \frac{1}{16} \neq \frac{1}{32} = \frac{1}{8} \cdot \frac{1}{4} = \mathbb{P}(X = 0) \cdot \mathbb{P}(Y = 0) \tag{31}$$

Hier reicht es ein Gegenbeispiel zu finden, da (30) für alle Paare gelten muss.

## 4.3 Faltungsformel

Seien $X$ und $Y$ zwei unabhängige diskrete Zufallsvariablen auf $(\Omega, \mathbb{P})$. Dann hat die Zufallsvariable $X + Y$ die Verteilung

$$\mathbb{P}(X + Y = k) = \sum_{m \in X(\Omega)} \mathbb{P}(X = m) \cdot \mathbb{P}(Y = k - m) \tag{32}$$

# 5. Verteilungen

Hier ein paar wichtige Verteilungen im Überblick

## 5.1 Gleichverteilung

Hier sind alle Werte gleich wahrscheinlich. Man kann die Gleichverteilung auch noch in zwei Fälle unterteilen: Die diskrete Gleichverteilung und die stetige Gleichverteilung.

Der Unterschied zwischen diskreter und stetiger ist, dass die diskrete Gleichverteilung auf einem diskreten, also einem endlichen, Wertebereich definiert ist.

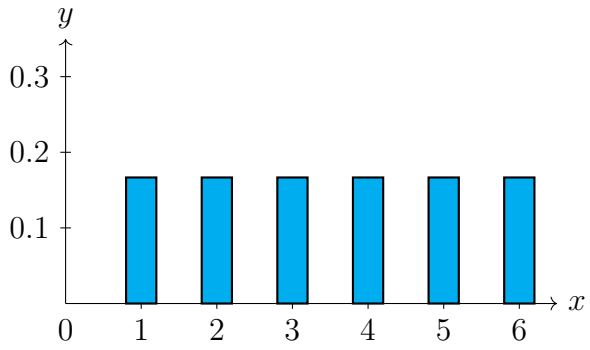


Abbildung 3: Diskrete Gleichverteilung ($n = 6$)

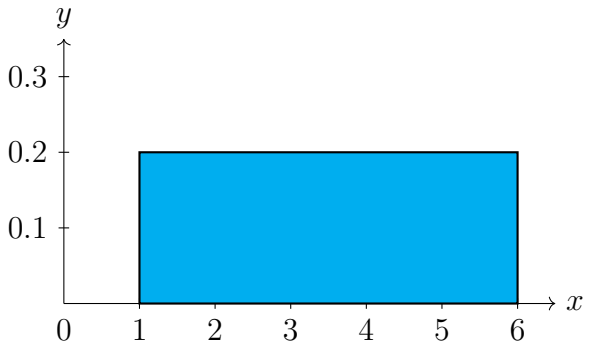


Abbildung 4: Stetige Gleichverteilung (Dichtefunktion mit $a = 1, b = 6$)

In Abbildung 3 gibt es insgesamt 6 Werte, jeder hat eine Wahrscheinlichkeit von $\frac{1}{6} = 0.1\bar{6}$. Bei der stetigen Gleichverteilung in Abbildung 4 hingegen hat jeder Wert die Wahrscheinlichkeit von 0, da es unendlich viele Werte gibt. Hier kann man nur die Wahrscheinlichkeit für ein bestimmtes Intervall finden.

## 5.2 Bernoulli-Verteilung

Eine Bernoulli-Verteilung ist die Verteilung eines Experimentes, wo es nur 0 oder 1 als Ausgang gibt wie z.B. beim Münzwürf „Es wurde Kopf geworfen“ oder „Beim Würfeln wurde eine 6 geworfen“. Hier gibt es nur Ja oder Nein.

## 5.3 Binomialverteilung

Die Binomialverteilung ist stammt in gewisser Weise von der Bernoulli-Verteilung ab. Sie beschreibt nämlich die Anzahl der Erfolge in einer Serie von gleichartigen und unabhängigen Versuchen, die jeweils zwei mögliche Ausgänge haben.

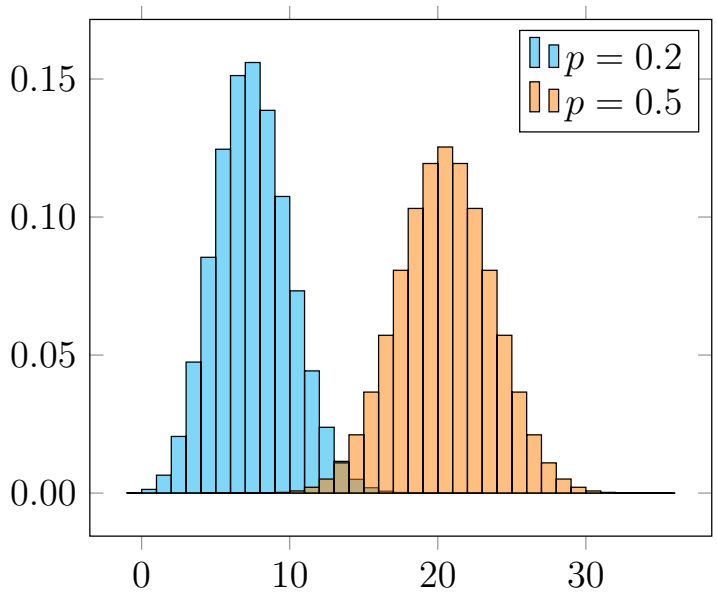


Abbildung 5: Binomialverteilung von $\mathrm{Bin}(40, 0.2)$ und $\mathrm{Bin}(40, 0.5)$

## 5.4 Geometrische Verteilung

Die Geometrische Verteilung ist die Wahrscheinlichkeitsverteilung der Anzahl der Bernoulli-Versuche, die notwendig sind um einen Erfolg zu haben.

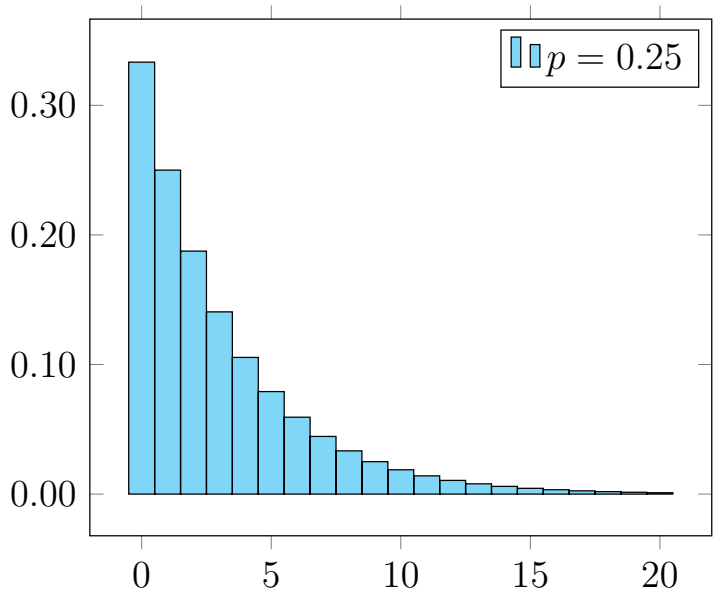


Abbildung 6: Geometrische Verteilung von $p = 0.25$

## 5.5 Poisson-Verteilung

Die Poisson-Verteilung ist eine Verteilung mit der die Anzahl von unabhängigen Ereignissen modelliert werden kann. Sie stellt einen Grenzwert bzw. eine gute Approximation für die Binomialverteilung dar. Der Parameter $\lambda$ ist gleichzeitig Erwartungswert und Varianz.

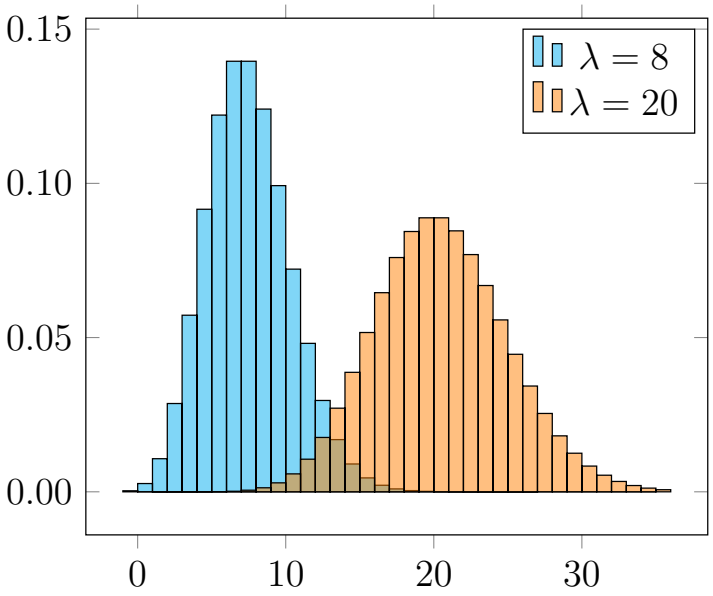


Abbildung 7: Poisson-Verteilung von $\lambda = 8$ und $\lambda = 20$

Hier sieht man sehr gut, dass Abbildung 5 und Abbildung 7 (fast) übereinstimmen.

## 5.6 Exponentialverteilung

Die Exponentialverteilung ist eine stetige Wahrscheinlichkeitsverteilung, die durch die exponentialfunktion gegeben ist. Sie wird als Modell vorrangig bei der Beantwortung der Frage nach der Dauer von zufälligen Zeitintervallen benutzt, wie z.B.

- Zeit zwischen zwei Anrufen
- Lebensdauer von Atomen beim radioaktiven Zerfall
- Zeit zwischen zwei Unfällen auf einer bestimmten Straße

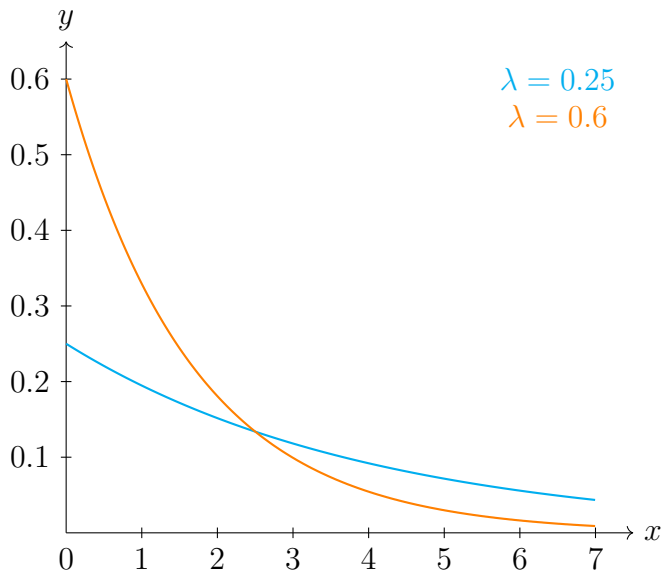


Abbildung 8: Exponentialverteilung von Exp(0.25) und Exp(0.6)

## 5.7 Normalverteilung

Die besondere Bedeutung der Normalverteilung beruht unter anderem auf dem zentralen Grenzwertsatz, dem zufolge Verteilungen, die durch additive Überlagerung einer großen Zahl von unabhängigen Einflüssen entstehen, unter schwachen Voraussetzungen annähernd normalverteilt sind.

Die Abweichungen der Messwerte vieler natur-, wirtschafts- und ingenieurwissenschaftlicher Vorgänge vom Erwartungswert lassen sich durch die Normalverteilung entweder exakt oder wenigstens in sehr guter Näherung beschreiben.

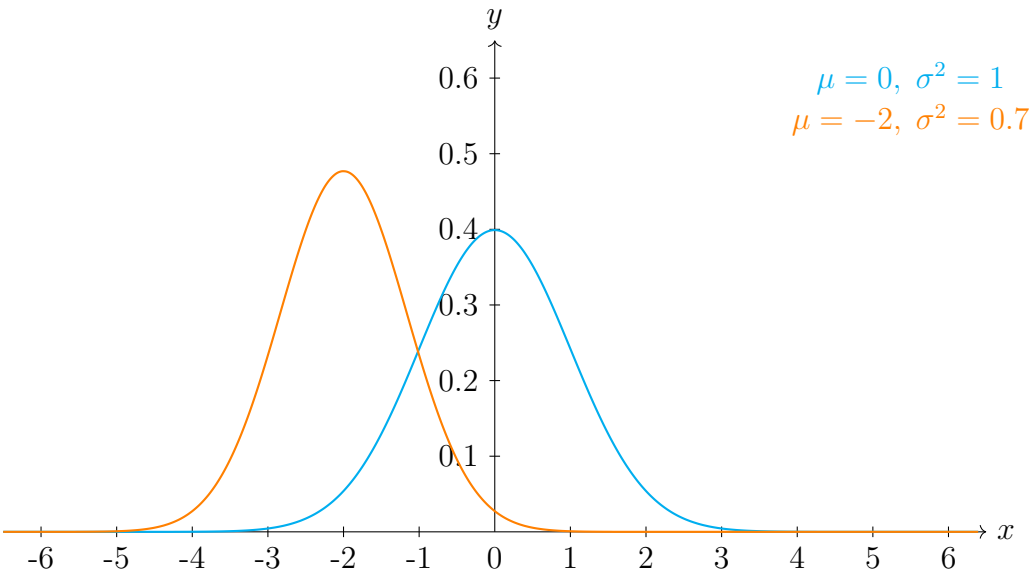


Abbildung 9: Normalverteilung von $\mathcal{N}(0,1)$ und $\mathcal{N}(-2,0.7)$

Die Dichtefunktion der Normalverteilung lässt sich nicht auf eine elementare Stammfunktion zurückführen. Deswegen werden für die Berechnungen meist Tabellen benutzt.

### Transformation

Eine nützliche Eigenschaft ist die Möglichkeit eine normalverteilte Zufallsvariablen zu normieren. Sei $X \sim \mathcal{N}(\mu, \sigma^2)$. Dann ist

$$Y = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0,1) \tag{33}$$

Darüber hinaus kann jede Zufallsvariable nach dem Zentralen Grenzwertsatz (76), für große $n$, auf $\mathcal{N}(0,1)$ normiert werden. Diese Transformation darf gemacht werden, wenn $n \cdot p \geq 5$ und $n \cdot (1-p) \geq 5$ gilt.

Außerdem ist die Normalverteilung Symmetrisch bezüglich der $y$-Achse, es gilt also $f(x) = f(-x)$. Es gilt also für $Y \sim \mathcal{N}(0,1)$:

$$\mathbb{P}(Y \leq -a) = \mathbb{P}(Y > a) = 1 - \mathbb{P}(Y \leq a) \tag{34}$$

## 5.8 Chi-Quadrat-Verteilung

Die $\chi^2$-Verteilung ist eine der Verteilungen, die aus der Normalverteilung abgeleitet werden kann: Hat man $n$ Zufallsvariablen $X_i$, die unabhängig und standardnormalverteilt sind, so ist die Chi-Quadrat-Verteilung mit $n$ Freiheitsgraden definiert als die Verteilung der Summe der quadrierten Zufallsvariablen $X_1^2 + \ldots + X_n^2$.

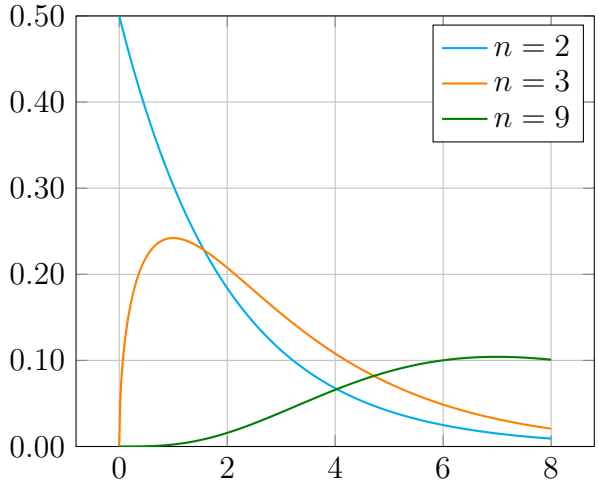


Abbildung 10: $\chi^2$-Verteilung von $n = 2, 3, 9$

## 5.9 $t$-Verteilung

Die $t$-Verteilung erlaubt – insbesondere für kleine Stichprobenumfänge – die Berechnung der Verteilung der Differenz vom Mittelwert der Stichprobe zum wahren Mittelwert der Grundgesamtheit. Diese wird für den Schätzer von $\mu$ einer normalverteilten Zufallsvariable mit unbekanntem Erwartungswert $\mu$ und unbekannter Varianz $\sigma^2$ verwendet.

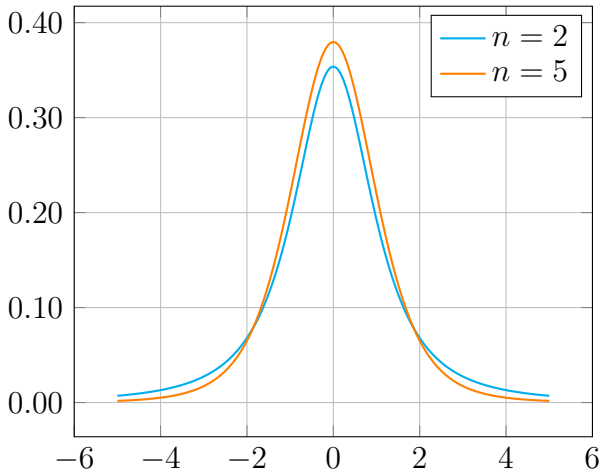


Abbildung 11: $t$-Verteilung von $n = 2, 5$

## 5.10 Wahrscheinlichkeiten von diskreten Verteilungen

| Name | Parameter | $X(\Omega)$ | $\mathbb{P}(X = k)$ | $\mathbb{E}[X]$ | $\mathbb{V}[X]$ |
|---|---|---|---|---|---|
| Diskrete Gleichverteilung | $n \in \mathbb{N}$ | $\{1, \ldots, n\}$ | $\frac{1}{n}$ | $\frac{n+1}{2}$ | $\frac{n^2-1}{12}$ |
| Bernoulli-Verteilung | $p \in [0,1]$ | $\{0, 1\}$ | $p^k \cdot (1-p)^{1-k}$ | $p$ | $p \cdot (1-p)$ |
| Binomial-Verteilung | $p \in [0,1], n \in \mathbb{N}$ | $\{0, \ldots, n\}$ | $\binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$ | $n \cdot p$ | $n \cdot p \cdot (1-p)$ |
| Geometrische Verteilung | $p \in [0,1], n \in \mathbb{N}$ | $\mathbb{N}$ | $(1-p)^{n-1} \cdot p$ | $\frac{1}{p}$ | $\frac{1-p}{p^2}$ |
| Zipf-Verteilung | $a > 1$ | $\mathbb{N}$ | $\frac{k^{-a}}{\sum_{k=1}^{\infty} k^{-a}}$ | $\frac{\zeta(a-1)}{\zeta(a)}$ | – |
| Poisson-Verteilung | $\lambda > 0$ | $\mathbb{N}_0$ | $\frac{\lambda^k}{k!} \cdot \mathrm{e}^{-\lambda}$ | $\lambda$ | $\lambda$ |

## 5.11 Wahrscheinlichkeiten von stetigen Verteilungen

| Name | Parameter | $X(\Omega)$ | $f_X(x)$ | $F_X(x)$ | $\mathbb{E}[X]$ | $\mathbb{V}[X]$ |
|---|---|---|---|---|---|---|
| Stetige Gleichverteilung | $a, b \in \mathbb{R}$ | $[a, b]$ | $\frac{1}{b-a}, \quad x \in [a, b]$ | $\frac{x-a}{b-a}, \quad x \in [a, b]$ | $\frac{a+b}{2}$ | $\frac{(b-a)^2}{12}$ |
| Exponentialverteilung | $\lambda > 0$ | $\mathbb{R}^+$ | $\lambda \cdot \mathrm{e}^{-\lambda \cdot x}, \quad x > 0$ | $1 - \mathrm{e}^{-\lambda \cdot x}, \quad x > 0$ | $\frac{1}{\lambda}$ | $\frac{1}{\lambda^2}$ |
| Normalverteilung | $\mu, \sigma \in \mathbb{R}$ | $\mathbb{R}$ | $\frac{1}{\sqrt{2\pi\sigma^2}} \cdot \mathrm{e}^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$ | Nicht integrierbar | $\mu$ | $\sigma^2$ |
| $\chi^2$-Verteilung | $n \in \mathbb{N}$ | $\mathbb{R}^+$ | $\frac{x^{\frac{n}{2}-1} \cdot \mathrm{e}^{-\frac{x}{2}}}{2^{\frac{n}{2}} \cdot \Gamma\left(\frac{n}{2}\right)}, \quad x > 0$ | $1 - \mathrm{e}^{-\frac{x}{2}} \sum_{k=0}^{n/2-1} \frac{1}{\Gamma\left(k + \frac{3}{2}\right)} \left(\frac{x}{2}\right)^k, \quad x > 0$ | $n$ | $2n$ |
| $t$-Verteilung | $n \in \mathbb{N}$ | $\mathbb{R}$ | $\frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \cdot \Gamma\left(\frac{n}{2}\right)} \cdot \left(1 + \frac{x^2}{n}\right)^{\frac{n+1}{2}}, \; x \in \mathbb{R}$ | Integrierbar, aber nicht aufgelistet | $0$ | $\frac{n}{n-2}$ |

# 6. Erwartungswert

Der Erwartungswert ist definiert als

$$\mathbb{E}[X] = \sum_{k \in X(\Omega)} k \cdot \mathbb{P}(X = k) \tag{35}$$

Das ist der Wert, den wir erwarten würden. Z.B. beim Würfel:

$$\begin{aligned} \sum_{k=1}^{6} k \cdot \mathbb{P}(X = k) &= \sum_{k=1}^{6} k \cdot \frac{1}{6} = \frac{1}{6} \cdot 21 \\ &= 3.5 \end{aligned} \tag{36}$$

Man erwartet also für jeden Würfel einen Wert von 3.5. Dass dieser Wert nicht angenommen werden kann ist klar, es ist ja auch nur das, was wir im Mittel erwarten.

## 6.1 Eigenschaften

Es gelten folgende Eigenschaften:

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \tag{37}$$

$$\forall a \in \mathbb{R} : \mathbb{E}[a \cdot X] = a \cdot \mathbb{E}[X] \tag{38}$$

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y] + \operatorname{cov}(X, Y) \tag{39}$$

$$(\forall w \in \Omega : X(\omega) \geq 0) \Rightarrow \mathbb{E}[X] \geq 0 \tag{40}$$

Sei $g : \mathbb{R} \to \mathbb{R}$ eine Funktion. Dann gilt

$$\mathbb{E}[g(X)] = \sum_{k \in X(\Omega)} g(k) \cdot \mathbb{P}(X = k) \tag{41}$$

## 6.2 Dichte

Falls die Zufallsvariable eine Dichte $f$ besitzt ist der Erwartungswert wie folgt definiert:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot f_X(x) \, \mathrm{d}x \tag{42}$$

Für eine Funktion $g : \mathbb{R} \to \mathbb{R}$ ist der Erwartungswert wie folgt definiert:

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) \, \mathrm{d}x \tag{43}$$

# 7. Varianz

Die Varianz ist definiert als

$$\mathbb{V}[X] = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] \tag{44}$$

Dies ist ein Maß für die Streuung. Man kann sie auch über folgende Formel berechnen:

$$\mathbb{V}[X] = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2 \tag{45}$$

Sei $X$ eine Zufallsvariable, deren Varianz existiert. Dann heißt $\sigma(X) = \sqrt{\mathbb{V}[X]}$.

Seien $X$ und $Y$ zwei Zufallsvariablen, deren Varianzen existieren. Dann gelten folgende Eigenschaften

$$\mathbb{V}[a \cdot X + b] = a^2 \cdot \mathbb{V}[X] \tag{46}$$

$$\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y] + 2\operatorname{cov}(X, Y) \tag{47}$$

Falls die Zufallsvariable eine Dichte $f$ besitzt, ist die Varianz durch folgende Formel gegeben

$$\mathbb{V}[X] = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 \cdot f(x)\,\mathrm{d}x \tag{48}$$

## 7.1 Chebyshev-Ungleichung

Sei $X$ eine Zufallsvariable deren Varianz existiert. Dann gilt für jedes $a > 0$

$$\mathbb{P}(|X - \mathbb{E}[X]| > a) \leq \frac{\mathbb{V}[X]}{a^2} \tag{49}$$

## 7.2 Markov-Ungleichung

Die Markov-Ungleichung ist eine Verallgemeinerung der Chebyshev-Ungleichung. Sei $X$ eine Zufallsvariable und sei $f : \mathbb{R} \to [0, \infty)$ eine monoton wachsende Funktion. Falls $\exists\, \mathbb{E}[f(X)]$ so gilt für jedes $a \in \mathbb{R}$

$$\mathbb{P}(X > a) \leq \frac{\mathbb{E}[f(X)]}{f(a)} \tag{50}$$

# 8. Kovarianz

Seien $X$ und $Y$ zwei Zufallsvariablen auf $(\Omega, \mathbb{P})$. Die Kovarianz von $X$ und $Y$ ist definiert als

$$\operatorname{cov}(X, Y) = \mathbb{E}[X]((X - \mathbb{E}[X] \cdot (Y - \mathbb{E}[Y])) \tag{51}$$

falls die Erwartungswerte existieren. Falls $\operatorname{cov}(X, Y) > 0$ so heißen $X$ und $Y$ positiv korreliert. Das heißt: Wenn $X$ hohe Werte annimmt, so nimmt auch $Y$ hohe Werte an. Falls $\operatorname{cov}(X, Y) < 0$ so heißen $X$ und $Y$ negativ korreliert. Das heißt: Wenn $X$ hohe Werte annimmt, so nimmt $Y$ niedrige Werte an. Andernfalls heißen sie unkorreliert.

Man kann die Kovarianz auf über folgende formel berechnen:

$$\operatorname{cov}(X, Y) = \mathbb{E}[X \cdot Y] - \mathbb{E}[X] \cdot \mathbb{E}[X] \tag{52}$$

## 8.1 Eigenschaften

Seien $X, Y, Z$ Zufallsvariablen auf $(\Omega, \mathbb{P})$ mit positiver Varianz und seien $a, b \in \mathbb{R}$. Dann gelten folgende Eigenschaften

$$\operatorname{cov}(X, Y) = \operatorname{cov}(Y, X) \tag{53}$$

$$\operatorname{cov}(X, X) = \mathbb{V}[X] \tag{54}$$

$$\operatorname{cov}(aX + bY, Z) = a \cdot \operatorname{cov}(X, Z) + b \cdot \operatorname{cov}(Y, Z) \tag{55}$$

$$X \text{ und } Y \text{ unabhängig} \Rightarrow \operatorname{cov}(X, Y) = 0 \tag{56}$$

## 8.2 Korrelation

Die Kovarianz gibt zwar die Richtung einer Beziehung zwischen zwei Zufallsvariablen an, aber über die Stärke des Zusammenhangs wird aber keine Aussage getroffen. Dies liegt an der Linearität der Kovarianz. Um einen Zusammenhang vergleichbar zu machen, muss die Kovarianz normiert werden. Die gebräuchlichste Normierung mittels der Standardabweichung führt zum Korrelationskoeffizienten.

Seien $X, Y$ zwei Zufallsvariablen mit positiver Varianz auf $(\Omega, \mathbb{P})$. Der Korrelationskoeffizient von $X$ und $Y$ ist definiert als

$$\varrho(X, Y) = \operatorname{corr}(X, Y) = \frac{\operatorname{cov}(X, Y)}{\sqrt{\mathbb{V}[X] \cdot \mathbb{V}[Y]}} \tag{57}$$

## 8.3 Kovarianzmatrix

Seien $X_1, \ldots, X_n$ Zufallsvariablen auf $(\Omega, \mathbb{P})$. Die Kovarianzmatrix von $X_1, \ldots, X_n$ ist

$$\begin{pmatrix} \operatorname{cov}(X_1, X_1) & \operatorname{cov}(X_1, X_2) & \cdots & \operatorname{cov}(X_1, X_n) \\ \operatorname{cov}(X_2, X_1) & \operatorname{cov}(X_2, X_2) & \cdots & \operatorname{cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \operatorname{cov}(X_n, X_1) & \operatorname{cov}(X_n, X_2) & \cdots & \operatorname{cov}(X_n, X_n) \end{pmatrix} \tag{58}$$

# 9. Markov-Ketten

Sei $S$ eine (höchstens abzählbare) Menge. Eine Markov-Kette auf $S$ ist eine Folge von Zufallsvariablen $X_0, X_1, \ldots$ auf $(\Omega, \mathbb{P})$ mit Werten in $S$ so, dass
$\forall n \in \mathbb{N}_0 \wedge \forall a_0, a_1, \ldots, a_n \in S$ gilt

$$\mathbb{P}(X_n = a_n \mid X_0 = a_0, \ldots X_{n-1} = a_{n-1}) = \mathbb{P}(X_n = a_n \mid X_{n-1} = a_{n-1}) \tag{59}$$

$$= \mathbb{P}(X_1 = a_n \mid X_0 = a_{n-1}) \tag{60}$$

Die Übergangswahrscheinlichkeiten hängen also nur von dem aktuellen Zustand ab und nicht von der gesamten Vergangenheit.

## 9.1 Übergangswahrscheinlichkeiten

Sei $X_0, X_1, \ldots$ eine Markov-Kette auf einem Zustandsraum $S$. Seien $a, b \in S$. Dann heißt

$$p_{a,b} = \mathbb{P}(X_n = b \mid X_{n-1} = a) \tag{61}$$

Übergangswahrscheinlichkeit von $a$ nach $b$. Diese lassen sich dann in eine quadratische Übergangsmatrix (für einen endlichen Zustandsraum $S = \{a_1, \ldots, a_K\}$) zusammenfassen:

$$P = (p_{a_n,a_m})_{n,m=1,\ldots,K} = \begin{pmatrix} p_{a_1,a_1} & p_{a_1,a_2} & \cdots & p_{a_1,a_n} \\ p_{a_2,a_1} & p_{a_2,a_2} & \cdots & p_{a_2,a_n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{a_n,a_1} & p_{a_n,a_2} & \cdots & p_{a_n,a_n} \end{pmatrix} \tag{62}$$

Diese Matrix hat folgende Eigenschaften

$$\forall a, b \in S : 0 \leq p_{a,b} \leq 1 \tag{63}$$

$$\forall a \in S : \sum_{b \in S} p_{a,b} = 1 \tag{64}$$

Eine Matrix mit diesen zwei Eigenschaften heißt stochastische Matrix. Jede Übergangsmatrix einer Markov-Kette ist eine stochastische Matrix, und umgekehrt existiert zu jeder stochastischen Matrix eine Markov-Kette.

Die Übergangsmatrix kann auch als Graph dargestellt werden. Für das Beispiel

$$P = \begin{pmatrix} \frac{1}{2} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & 0 \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & 0 & 0 \\ \frac{3}{16} & \frac{3}{16} & \frac{1}{4} & \frac{3}{16} & \frac{3}{16} \\ \frac{2}{5} & 0 & \frac{2}{5} & \frac{1}{5} & 0 \\ 0 & 0 & \frac{5}{6} & 0 & \frac{1}{6} \end{pmatrix} \tag{65}$$

sieht der Übergangsgraph wie folgt aus:

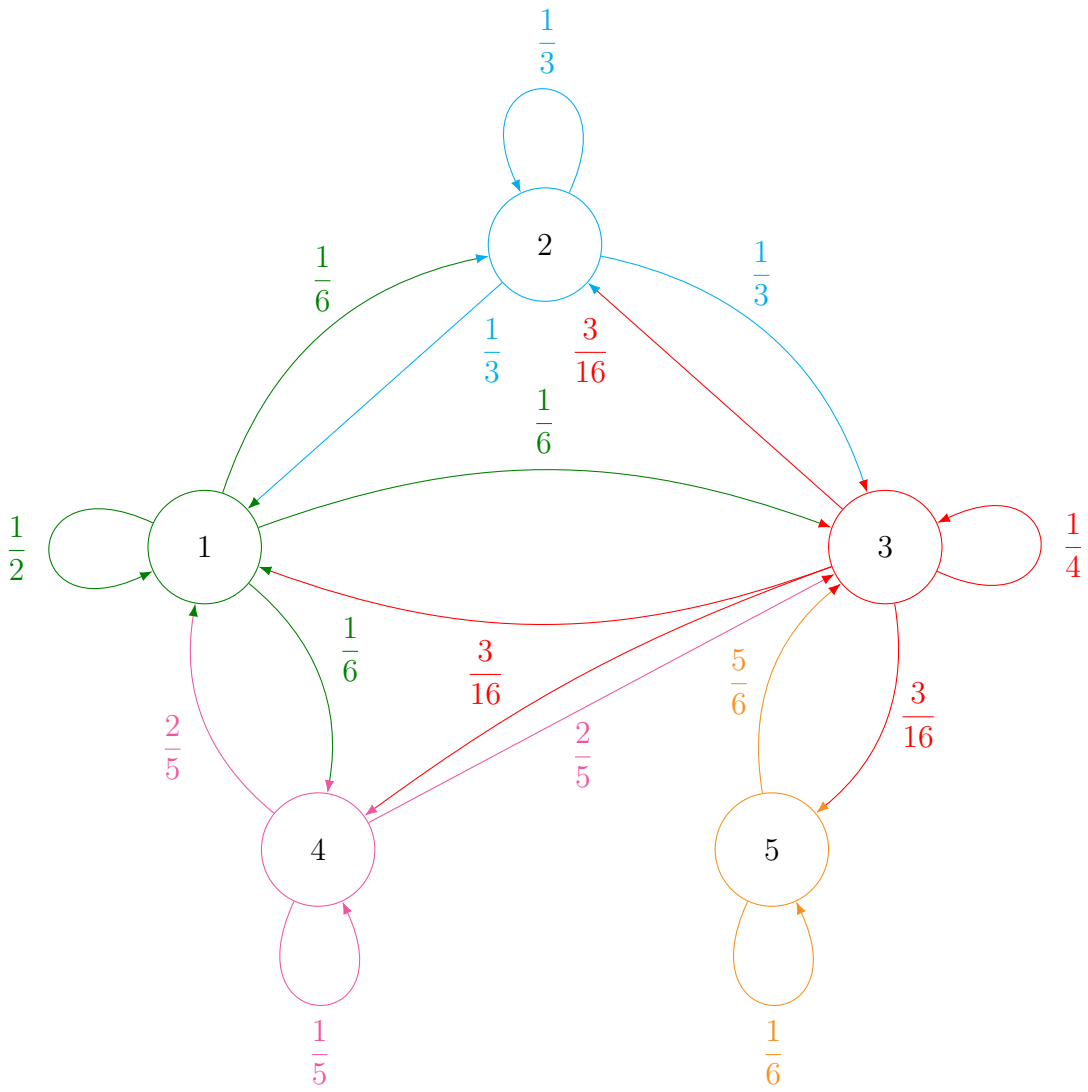

## 9.2 Startverteilung

Der Vektor $\nu = (\nu_a)_{a \in S}$ heißt Startverteilung der Markov-Kette. Mit dieser Startverteilung und der Übergangsmatrix $P$ kann man die Wahrscheinlichkeit für jeden Zustand $b \in S$ wie folgt berechnen

$$\mathbb{P}(X = b) = \sum_{a \in S} \nu(a) \cdot p_{a,b}^{(n)} \tag{66}$$

## 9.3 Invariante Verteilung

Sei $X_0, X_1, \ldots$ eine homogene Markov-Kette mit Zustandsraum $S$. Ein Vektor $(\pi_a)_{a \in S}$ heißt invariante Verteilung für die Markov-Kette falls folgende Eigenschaften gelten

$$\pi_a = \sum_{b \in S} \pi_b \cdot p_{b,a} \tag{67}$$

$$\forall a \in S : \pi_a \geq 0 \tag{68}$$

$$\sum_{a \in S} \pi_a = 1 \tag{69}$$

(67) kann umformuliert werden zu

$$\pi^T = \pi^T \cdot P \tag{70}$$

Man sucht hier also den normierten Eigenvektor von $P$ zu dem Eigenwert $\lambda = 1$.

## 9.4 Bestimmung von invarianten Verteilungen

Es muss (70) gefunden werden:

$$\pi^T = \pi^T \cdot P \tag{71}$$

$$\Leftrightarrow \qquad (P - I)^T \cdot \pi = 0 \tag{72}$$

Dies ist ein lineares Gleichungssystem welches z.B. über den Gauß-Algorithmus oder durch scharfes hinsehen gelöst werden kann.

Eine Markov-Kette auf einem endlichen Zustandsraum hat immer mindestens eine invariante Verteilung. Falls die Kette irreduzibel ist, so ist die invariante Verteilung eindeutig.

Falls die Kette in einer (beliebigen) Startverteilung $\nu$ startet, befindet sie sich nach hinreichend langer Zeit in der stationären Verteilung.

## 9.5 Irreduzierbarkeit und Aperiodizität

Eine Markov-Kette heißt irreduzibel, falls für jede Wahl von zwei Zuständen $a, b \in S$ ein Pfad existiert, welcher $a$ und $b$ verbindet. Das heißt, dass der Graph zusammenhängend ist.

Eine irreduzible Markov-Kette heißt aperiodisch, falls für alle $a \in S$ gilt

$$\text{ggT}\,\{k \in \mathbb{N} \mid \exists \text{Pfad der Länge } k \text{ von } a \text{ nach } a\} = 1 \tag{73}$$

# 10. Gesetz der großen Zahlen

Sei $(X_i)_{i \in \mathbb{N}}$ eine Folge von unabhängigen, identisch verteilten Zufallsvariablen auf $(\Omega, \mathbb{P})$ mit $\mathbb{V}[X_i] < \infty$. Dann gilt

$$\lim_{n \to \infty} \left( \frac{1}{n} \cdot \sum_{i=1}^{n} X_i \right) = \mathbb{E}[X_i] \tag{74}$$

Daraus folgt

$$\sum_{i=1}^{n} X_i \approx n \cdot \mathbb{E}[X_1] \tag{75}$$

In anderen Worten: Die relative Häufigkeit eines Zufallsergebnisses stabilisiert sich in der Regel um die theoretische Wahrscheinlichkeit eines Zufallsergebnisses $\mathbb{E}[X]$, wenn das zugrundeliegende Zufallsexperiment immer wieder unter denselben Voraussetzungen durchgeführt wird.

# 11. Zentraler Grenzwertsatz

Sei $(X_i)_{i \in \mathbb{N}}$ eine Folge von unabhängigen, identisch verteilten Zufallsvariablen auf $(\Omega, \mathbb{P})$ mit $\mathbb{E}[X_1] = \mu$ und $\mathbb{V}[X_1] = \sigma^2 \in (0, \infty)$. Dann gilt für $x \in \mathbb{R}$

$$\lim_{n \to \infty} \left( \mathbb{P} \left( \frac{1}{\sqrt{n}} \cdot \sum_{i=1}^{n} \frac{X_i - \mu}{\sigma} \leq x \right) \right) = \Phi_{0,1}(x) \tag{76}$$

Das heißt, dass die Zufallsvariable

$$Y = \frac{1}{\sqrt{n}} \cdot \sum_{i=1}^{n} \frac{X_i - \mu}{\sigma} \tag{77}$$

für große $n$ standardnormalverteilt ist.

# 12. Statistik

Statistik ist die Lehre von Methoden zum Umgang mit quantitativen Informationen, also Daten. Sie ist eine Möglichkeit eine systematische Verbindung zwischen Erfahrung und Theorie herzustellen.

Die gemessenen Daten $x_1, \ldots, x_n$ können einzelne Realisierungen von Zufallsvariablen $X_1, \ldots, X_n$ oder eine Stichprobe aus einer Population darstellen. Mithilfe dieser Annahmen möchte man Aussagen über die zugrunde liegenden Zufallsvariablen machen.

## 12.1 Empirisches Mittel

Sei $(x_1, \ldots, x_n) \in \mathbb{R}^n$ ein Vektor. Das empirische Mittel ist definiert als

$$\overline{\mu}_n(x_1, \ldots, x_n) = \overline{\mu}_X = \frac{1}{n} \sum_{i=1}^{n} x_i \tag{78}$$

Das empirische Mittel ist auch unter dem Namen Durchschnitt bekannt.

## 12.2 Median

Der Median von $(x_1, \ldots, x_n)$ ist definiert als der Wert in der Mitte der Liste. Falls $n$ gerade ist, wird der Mittelwert aus beiden gebildet.

## 12.3 Empirische Varianz

Sei $(x_1, \ldots, x_n) \in \mathbb{R}^n$ ein Vektor. Die empirische Varianz ist definiert als

$$\overline{\sigma}_n^2(x_1, \ldots, x_n) = \overline{\sigma}_X^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{\mu}_X)^2 \tag{79}$$

Wichtig ist hier, dass durch $n-1$, der Anzahl der Freiheitsgrade, geteilt wird. Dies lässt sich wie folgt erklären: Aufgrund der Schwerpunkteigenschaft des empirischen Mittels ist die letzte Abweichung von $\sum\limits_{i=1}^{n}(x_i - \overline{\mu}_X) = 0$, also $(x_n - \overline{\mu}_X)$ bereits durch die ersten $n-1$ bestimmt. Es variieren nur $n-1$ Abweichungen frei und man mittelt deshalb, indem man durch die Anzahl der Freiheitsgerade $n-1$ dividiert.

## 12.4 Empirische Kovarianz

Seien $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$ gegeben. Die empirische Kovarianz ist definiert als

$$c_{x,y} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{\mu}_X) \cdot (y_i - \overline{\mu}_Y) \tag{80}$$

Der empirische Korrelationskoeffizient ist definiert als

$$r_{x,y} = \frac{c_{x,y}}{\overline{\sigma}_X \cdot \overline{\sigma}_Y} \tag{81}$$

## 12.5 Schätzfunktion

Seien $X_1, \ldots, X_n$ Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$. Eine Schätzfunktion zur Stichprobengröße $n$ ist eine Funktion

$$\theta_n : \mathbb{R}^n \to \mathbb{R}, \quad (X_1, \ldots, X_n) \mapsto \theta_n(X_1, \ldots, X_n) \tag{82}$$

So sind z.B. das empirische Mittel und die emprische Varianz Schätzer für das Mittel bzw. Varianz der zugrunde liegenden Zufallsvariablen.

## 12.6 Maximum Likelihood Schätzung

Gegeben sei eine Realisierung $(x_1, \ldots, x_n)$ der Zufallsvariablen $X_1, \ldots, X_n$ mit unbekanntem Parameter $\theta$. Sei $p_\theta(x)$ die Verteilung der $X_1, \ldots, X_n$ mit unbekanntem $\theta$. Betrachte

$$\mathbb{P}_\theta(X_1 = x_1, \ldots, X_n = x_n) = p_\theta(x_1) \cdot \ldots \cdot p_\theta(x_n) \tag{83}$$

Nun gilt es $\theta$ so zu bestimmen, dass die Wahrscheinlichkeit für vorgegebene $x = (x_1, \ldots, x_n)$ maximal ist. Dies kann durch ableiten und dann Nullstellen geschehen. Falls $X_i$ eine diskrete Verteilung $p_\theta$ mit Parameter $\theta$ zugrunde liegt so ist

$$L((x_1, \ldots, x_n); \theta) = p_\theta(x_1) \cdot \ldots \cdot p_\theta(x_n) = \prod_{i=1}^{n} p_\theta(x_i) \tag{84}$$

die Likelihood-Funktion. Falls $X_i$ eine Dichte $f_\theta$ mit Parameter $\theta$ besitzt, so ist

$$L((x_1, \ldots, x_n); \theta) = f_\theta(x_1) \cdot \ldots \cdot f_\theta(x_n) = \prod_{i=1}^{n} f_\theta(x_i) \tag{85}$$

die Likelihood-Funktion.

Maximum Likelihood-Schätzer für $\theta$ ist

$$\theta_*(x_1, \ldots, x_n) = \operatorname{argmax}_{\theta \in \mathbb{R}} L((x_1, \ldots, x_n); \theta) \tag{86}$$

## 12.7 Log-Likelihood

Die Log-Likelihood-Funktion ist definiert als

$$l((x_1, \ldots, x_n); \theta) = \ln(L((x_1, \ldots, x_n); \theta)) \tag{87}$$

Die Funktion ist oft einfacherer zu maximieren, da

$$\ln\left(\prod_{i=1}^{n} p_\theta(x_i)\right) = \sum_{i=1}^{n} \ln(p_\theta(x_i)) \tag{88}$$

Da der Logarithmus eine streng monoton wachsende Funktion ist, ist jedes Minimum der Log-Likelihood-Funktion auch ein Minimum der Likelihood-Funktion. Ebenso ist jedes Maximum der Log-Likelihood-Funktion auch ein Maximum der Likelihood-Funktion. Daher ist es meist günstiger die Log-Likelihood-Funktion aufzustellen.

## 12.8 Vorgehen

1. Likelihood-Funktion $L((x_1, \ldots, x_n); \theta)$ aufstellen, je nachdem ob die Verteilung diskret oder eine Dichte besitzt
2. Die Log-Likelihood-Funktion $l((x_1, \ldots, x_n); \theta)$ durch logarithmieren bilden
3. Den Parameter $\theta$ der Log-Likelihood-Funktion maximieren indem die Funktion abgeleitet wird und Nullgestellt wird
4. Überprüfen, ob es sich tatsächlich um ein Maximum handelt: Zweite Ableitung bilden und den gefunden Parameter $\theta$ einsetzen. Falls dieser Wert $< 0$, so ist das Ergebnis maximal.

## 12.9 Eigenschaften von Schätzern

Sei $(x_1, \ldots, x_n) \in \mathbb{R}^n$ ein Vektor welche als Realisierungen von identisch verteilten Zufallsvariablen $X_1, \ldots, X_n$ mit Parameter $\theta$ auf einem Wahrscheinlichkeitsraum $(\Omega, \mathbb{P})$. Sei $\theta_n$ eine Schätzfunktion zur Stichprobengröße $n$.

$\theta_n$ ist ein erwartungstreuer Schätzer für $\theta$, falls

$$\mathbb{E}\left[\theta_n(X_1, \ldots, X_n)\right] = \theta \tag{89}$$

$\theta_n$ ist ein konsistenter Schätzer für $\theta$, falls

$$\lim_{n \to \infty} \theta_n(X_1, \ldots, X_n) = \theta \tag{90}$$

$\theta_n$ ist ein effizienter Schätzer für $\theta$, falls

$$\lim_{n \to \infty} \mathbb{V}\left[\theta_n(X_1, \ldots, X_n)\right] = 0 \tag{91}$$

## 12.10 Lineare Regression

Gegeben seien $x = (x_1, \ldots, x_n)$ und $y = (y_1, \ldots, y_n)$. Die Regressionsgerade

$$y = ax + b \tag{92}$$

besitzt folgende Parameter

$$a = \frac{c_{x,y}}{\overline{\sigma}_X^2} \tag{93}$$

$$b = \overline{\mu}_Y - a \cdot \overline{\mu}_X \tag{94}$$

# 13. Konfidenzbereiche

Seien $X_1, \ldots, X_n$ unabhängige, identische verteilte Zufallsvariablen, deren Verteilung von einem Parameter $\theta \in \Theta$ abhängt. Sei $\alpha \in (0,1)$ vorgegeben. Ein Konfidenzbereich für den Parameter $\theta$ zum Fehleniveau $\alpha$ ist eine Menge $J = J(X_1, \ldots, X_n)$, so dass

$$\forall \theta \in \Theta : \mathbb{P}_\theta(J \ni \theta) \geq 1 - \alpha \tag{95}$$

gilt. Dabei bezeichnet $\mathbb{P}_\theta$ die Wahrscheinlichkeit unter dem Parameterwert $\theta$.

Das Konfidenzintervall gibt den Bereich an, der bei unendlicher Wiederholung eines Zufallsexperiments mit einer gewissen Wahrscheinlichkeit $1 - \alpha$ die wahre Lage des Parameters einschließt.

# 14. Quantile

Sei $\beta \in [0,1]$ und sei $Y$ eine Zufallsvariable mit bekannter Verteilungsfunktion $F$. Das Quantil der Verteilung $Y$ zum Niveau $\beta$ ist die kleinste Zahl $q_\beta$, für die gilt

$$F_Y(q_\beta) = \mathbb{P}(Y \leq q_\beta) \geq \beta \tag{96}$$

Anschaulich ist ein Quantil ein Schwellenwert: ein bestimmter Anteil der Werte ist kleiner als das Quantil, der Rest ist größer. Das 25-%-Quantil beispielsweise ist der Wert, für den gilt, dass 25 % aller Werte kleiner sind als dieser Wert. Quantile formalisieren praktische Aussagen wie „25 % aller Frauen sind kleiner als 1.62m“ – wobei 1.62m hier das 25-%-Quantil ist.

## 14.1 Quantile der Normalverteilung

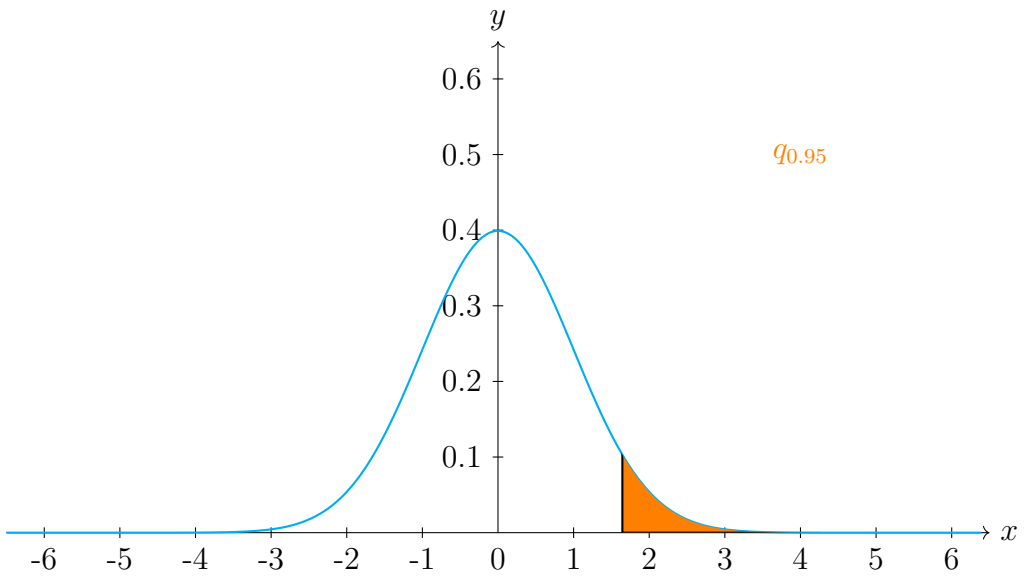


Abbildung 12: Das (rechtsseitige) 5% Quantil der Normalverteilung

# 15. Konstruktion von Konfidenzbereichen

Sei $X$ eine stetige Zufallsvariable, deren Verteilung von $\theta \in \Theta$ abhängt und sei $\alpha \in (0,1)$. Sei $x$ eine Realisierung von $X$. Der obere Konfidenzbereich zum Niveau $\alpha$ ist gegeben durch

$$J(x) = \{\theta \in \Theta : x \leq q_{\theta,\,1-\alpha}\} \tag{97}$$

Der untere Konfidenzbereich zum Niveau $\alpha$ ist gegeben durch

$$J(x) = \{\theta \in \Theta : x \geq q_{\theta,\,\alpha}\} \tag{98}$$

Der beidseitige Konfidenzbereich zum Niveau $\alpha$ ist gegeben durch

$$J(x) = \left\{\theta \in \Theta : q_{\theta,\,\alpha/2} \leq x \leq q_{\theta,\,1-\alpha/2}\right\} \tag{99}$$

Zu jedem Konfidenzbereich $J(x) \subset \Theta$ gehört ein Akzeptanzbereich $A(\theta) \subset \mathbb{R}$, so dass gilt

$$x \in A(\theta) \quad \Leftrightarrow \quad \theta \in J(x) \tag{100}$$

Es werden also alle $x$ angenommen, welche in $J(x)$ liegen.

## 15.1 Konfidenzbereich der Normalverteilung

Ein Konfidenzintervall zum Fehlerniveau $\alpha$ für den Erwartungswert $\mu$ einer Normalverteilung bei bekannter Varianz $\sigma^2$ und $n$ unabhängigen Messungen ist gegeben durch

$$J(n,\alpha,\sigma) = \left[\overline{\mu}_n - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}},\ \ \overline{\mu}_n + z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}\right] \tag{101}$$

## 15.2 Konfidenzintervall für den Erwartungswert der Normalverteilung

Seien $x_1, \ldots, x_n$ Messwerte von Realisierungen von unabhängigen, identisch normalverteilten Zufallsvariablen $X_1, \ldots, X_n$ mit unbekanntem Erwartungswert $\mu$ und unbekannter Varianz. Das Konfidenzintervall für $\mu$ erhält man als

$$J = \left[\overline{\mu}_n - \frac{\overline{\sigma}_n}{\sqrt{n}} \cdot t_{n-1,1-\alpha/2},\ \ \overline{\mu}_n + \frac{\overline{\sigma}_n}{\sqrt{n}} \cdot t_{n-1,1-\alpha/2},\ \ \right] \tag{102}$$

Hier gilt die Faustregel: Für $n > 30$ kann die $t$-Verteilung durch die Normalverteilung approximiert werden.

## 15.3 Konfidenzintervall für die Varianz der Normalverteilung

Seien $x_1, \ldots, x_n$ Messwerte von Realisierungen von unabhängigen, identisch normalverteilten Zufallsvariablen $X_1, \ldots, X_n$ mit bekanntem Erwartungswert $\mu$ und unbekannter Varianz. Das Konfidenzintervall für $\sigma^2$ erhält man als

$$J = \left[\overline{\sigma}_n^2 \cdot \frac{n-1}{\chi^2_{n-1,\,1-\alpha/2}},\ \ \overline{\sigma}^2 \cdot \frac{n-1}{\chi^2_{n-1,\,\alpha/2}}\right] \tag{103}$$

# 16. Testen von Hypothesen

Ein Test kann im Prinzip mit einem Gerichtsverfahren verglichen werden. Es wird zu Beginn zwei Hypothesen aufgestellt: $H_0$, die Nullhypothese „Der Angeklagte ist unschuldig“ und $H_1$, die Alternativhypothese „Der Angeklagte ist schuldig“. Man versucht dann $H_1$ zu beweisen. Die Nullhypothese wird nur dann verworfen, wenn es sehr unwahrscheinlich ist, dass diese richtig ist. Dies kann mithilfe von bestimmten Tests geschehen. Diesen Fehler (Fehler 1. Art) kann man kontrollieren, aber aufgrund der unsymmetrischen Art zwischen $H_0$ und $H_1$ wird dann der Fehler 2. Art größer. Man versucht also ein Optimum aus beiden zu finden.

Seien nun $x_1, \ldots, x_n$ Realisierungen von Zufallsvariablen $X_1, \ldots, X_n$, die gewisse Annahmen erfüllen. Falls unter $H_0$ diese Daten sehr unwahrscheinlich sind, wird $H_0$ verworfen und $H_1$ angenommen. Sehr unwahrscheinlich heißt hier ein Niveau $\alpha$, zu dem man entscheidet (z.B. mit 95% ist diese Entscheidung richtig).

## 16.1 Herangehensweise für ein Merkmal, einseitig

1. Wahl einer geeigneten Nullhypothese $H_0$: $\mu \leq \mu_0$
2. Wähle ein Fehlerniveau $\alpha \in (0, 1)$
3. Erhebe Daten $x_1, \ldots, x_n$
4. Bestimme den Freiheitsgrad $f$. Im $t$-Test ist $f = n - 1$
5. Bestimme $t_{1-\alpha,\, f}$, das $1 - \alpha$-Quantil der $t$-Verteilung zum Parameter $f$
6. Berechne $\overline{\mu}_n$ und $\overline{\sigma}_n = \sqrt{\overline{\sigma}_n^2}$ aus den Daten
7. Berechne den Testwert
$$t = \sqrt{n} \cdot \frac{\overline{\mu}_n - \mu_0}{\overline{\sigma}_n} \tag{104}$$
8. Vergleiche den Testwert $t$ mit $t_{1-\alpha,\, f}$. Entscheidungsregel:
   - Ist $t \geq t_{1-\alpha,\, f}$, so wird $H_0$ abgelehnt
   - Andernfalls wird $H_0$ angenommen

Falls die Nullhypothese $H_0$: $\mu_0 \leq \mu$ ist, werdem alle $\leq$ zu $\geq$ bzw. andersherum. $t_{1-\alpha,\, f}$ wird außerdem zu $t_{\alpha,\, f}$, ist also $t \leq t_{\alpha,\, f} = -t_{1-\alpha\, f}$ wird abgelehnt.

## 16.2 Herangehensweise für ein Merkmal, zweiseitig

1. Wahl einer geeigneten Nullhypothese $H_0$: $\mu = \mu_0$
2. Wähle ein Fehlerniveau $\alpha \in (0, 1)$
3. Erhebe Daten $x_1, \ldots, x_n$
4. Bestimme den Freiheitsgrad $f$. Im $t$-Test ist $f = n - 1$
5. Bestimme $t_{1-\alpha/2,\, f}$, das $1 - \alpha/2$-Quantil der $t$-Verteilung zum Parameter $f$
6. Berechne $\overline{\mu}_n$ und $\overline{\sigma}_n = \sqrt{\overline{\sigma}_n^2}$ aus den Daten
7. Berechne den Testwert
$$t = \sqrt{n} \cdot \frac{\overline{\mu}_n - \mu_0}{\overline{\sigma}_n} \tag{105}$$
8. Vergleiche den Testwert $t$ mit $t_{1-\alpha,\, f}$. Entscheidungsregel:
   - Ist $|t| \geq t_{1-\alpha/2,\, f}$, so wird $H_0$ abgelehnt
   - Andernfalls wird $H_0$ angenommen

## 16.3 Herangehensweise für zwei Merkmale, zweiseitig

1. Wahl einer geeigneten Nullhypothese $H_0$: $\mu_x = \mu_y$
2. Wähle ein Fehlerniveau $\alpha \in (0, 1)$
3. Erhebe Daten $x_1, \ldots, x_n$, $y_1, \ldots, y_m$
4. Bestimme den Freiheitsgrad $f$. Im $t$-Test ist $f = n + m - 2$
5. Bestimme $t_{1-\alpha/2,\, f}$, das $1 - \alpha/2$-Quantil der $t$-Verteilung zum Parameter $f$
6. Berechne $\overline{\mu}_x, \overline{\mu}_y$ und $\overline{\sigma}_x^2, \overline{\sigma}_y^2$ aus den Daten sowie
$$S^2 = \frac{(n-1) \cdot \overline{\sigma}_x^2 + (m-1) \cdot \overline{\sigma}_y^2}{n + m - 2} \tag{106}$$
7. Berechne den Testwert
$$t = \sqrt{\frac{n \cdot m}{n + m}} \cdot \frac{\overline{\mu}_x - \mu_y}{S} \tag{107}$$
8. Vergleiche den Testwert $t$ mit $t_{1-\alpha,\, f}$. Entscheidungsregel:
   - Ist $|t| \geq t_{1-\alpha/2,\, f}$, so wird $H_0$ abgelehnt
   - Andernfalls wird $H_0$ angenommen

## 16.4 Chi-Quadrat-Test

Den $\chi^2$-Test kann man in verschiedenen Situationen verwendet. Wenn man testen will, ob die Daten einer bestimmten Verteilung folgen oder als Test auf Unabhängigkeit zwischen zwei Zufallsvariablen.

### Chi-Quadrat-Test auf Verteilung

1. Gruppieren der Daten $x_1, \ldots, x_n$ in $k$ Klassen $A_1, \ldots, A_k$, wobei jedes $x_j$ in einer Klasse enthalten ist und die Klassen paarweise disjunkt sind. Nun wird die Häufigkeit bestimmt

$$N_i = |\{j : x_j \in A_i\}|, \quad i = 1, \ldots, k \tag{108}$$

2. Aufstellung der Nullhypothese $H_0$: Die Daten folgen einer bestimmten Verteilung
3. Wahl des Fehlerniveaus $\alpha \in (0, 1)$
4. Berechnung des Freiheitsgrads $f = k - m - 1$ wobei $m$ die Anzahl geschätzter Parameter in der angenommenen Verteilung ist.
5. Bestimmung des $1 - \alpha$-Quantils $\chi^2_{1-\alpha,\, f}$ der $\chi^2$-Verteilung
6. Berechnung der theoretischen Häufigkeiten unter der Nullhypothese:

$$F_i = n \cdot \mathbb{P}(X \in A_i \mid H_0), \quad i = 1, \ldots, k \tag{109}$$

7. Berechnung des Testwerts

$$\chi^2 = \sum_{i=1}^{k} \frac{(N_i - F_i)^2}{F_i} \tag{110}$$

8. Vergleich des Testwertes mit dem bestimmten Quantil
   - Ist $\chi^2 > \chi^2_{1-\alpha,\, f}$, so wird $H_0$ verworfen
   - Andernfalls wird $H_0$ angenommen

**Chi-Quadrat-Test auf Unabhängigkeit**

1. Gruppieren der $x_1, \ldots, x_n$ in $k$ paarweise disjunkte Gruppen $A_1, \ldots, A_k$ und $y_1, \ldots, y_n$ in $m$ paarweise disjunkte Gruppen $B_1, \ldots, B_m$. Bestimme die Häufigkeiten

$$N_{i,j} = |\{r : x_r \in A_i, \;\; y_r \in B_j\}| \tag{111}$$

   Aufstellen der Kontingenztafel mit diesen Häufigkeiten. Berechnung der Randhäufigkeiten $N_{i,*} = \sum\limits_{j=1}^{m} N_{i,j}$ und $N_{*,j}$

2. Aufstellen der Nullhypothese $H_0$: Die Daten $x$ sind unabhängig von den Daten $y$

3. Wahl des Fehlerniveaus $\alpha \in (0, 1)$

4. Berechnung des Freiheitsgrads $f = (k-1) \cdot (m-1)$

5. Bestimmung des $1-\alpha$-Quantils $\chi^2_{1-\alpha,\,f}$ der $\chi^2$-Verteilung

6. Berechnung der Theoretischen Häufigkeiten unter der Nullhypothese

$$F_{i,j} = \frac{N_{i,*} \cdot N_{*,j}}{n} \tag{112}$$

7. Berechnung des Testwerts

$$\chi^2 = \sum_{i,j} \frac{(F_{i,j} - N_{i,j})^2}{F_{i,j}} \tag{113}$$

8. Vergleich des Testwertes $\chi^2$ mit dem Quantil

   - Ist $\chi^2 > \chi^2_{1-\alpha,\,f}$, so wird $H_0$ abgelehnt.
   - Andernfalls wird $H_0$ angenommen.

## 16.5 $p$-Wert

Seien $X_1, \ldots, X_n$ Zufallsvariablen und $x_1, \ldots, x_n \in \mathbb{R}$ Daten. Sei $H_0$ eine Nullhypothese. Der rechtsseitige $p$-Wert für $H_0$ ist definiert als

$$p(x_1, \ldots, x_n) = \mathbb{P}(X_i \geq x_i,\ i = 1, \ldots, n \mid H_0) \tag{114}$$

der linksseitige $p$-Wert als

$$p(x_1, \ldots, x_n) = \mathbb{P}(X_i \leq x_i,\ i = 1, \ldots, n \mid H_0) \tag{115}$$

und der beidseitige $p$-Wert als

$$p(x_1, \ldots, x_n) = 2 \cdot \min \{\mathbb{P}(X_i \geq x_i,\ i = 1, \ldots, n \mid H_0),\ \ \mathbb{P}(X_i \leq x_i,\ i = 1, \ldots, n \mid H_0)\} \tag{116}$$

Sei $p(x)$ ein $p$-Wert zu den Daten $x = (x_1, \ldots, x_n)$. Dann ist

$$A_\alpha = \{x \mid p(x) \geq \alpha\} \tag{117}$$

ein Annahmebereich zum Fehlerniveau $\alpha$.